数学推理候选选择实验报告

DASE7506 MP2 2026年10月31日

摘要

最终方法在官方 467 道测试题中选对 393 道，准确率为 84.1542%；验证集为 755/798。方法先用文本、算式来源和官方 embedding 计算基础分数，再用小型神经网络和树模型修正，最后减弱并列排序特征中的候选顺序影响。全部推理资产未压缩为 643,525 字节，整理后的四线程完整 CPU 评测约 9.31 秒。

多数投票基线为 323/467。与旧项目 control 的 378/467 相比，最终方法多选对 15 题。开发期间多次查看过公开测试分数，因此这里报告的是冻结配置的复现成绩，不把它作为一次性盲测证据。

1 任务与数据

每道题给出四条 Qwen3-0.6B 候选解答，以及每条解答固定的 1024 维表示。选择器返回一个候选索引，不生成新解答。标签由官方数值解析器比较最终答案得到；候选最终数值正确，并不意味着其每一步推理都正确。官方仓库提供接口与独立评测器，没有提供参考选择算法。[1][2]

数据集	题数	分歧题数
train	4755	2114
validation	798	355
test	467	467

分歧题指四个候选中存在至少两个不同的有效解析答案。线性模型拟合 train 中含错误候选的 2513 题；网络和树只拟合 2114 道分歧题。每题四个候选始终属于同一训练折。

验证集另有 443 道非分歧题。屏蔽无效答案后，这些题不需要在不同数值之间选择。最终方法在验证集分歧部分为 312/355，即 87.89%；因此，不能直接用完整验证集的 94.61% 与测试集的 84.15% 判断泛化差距。

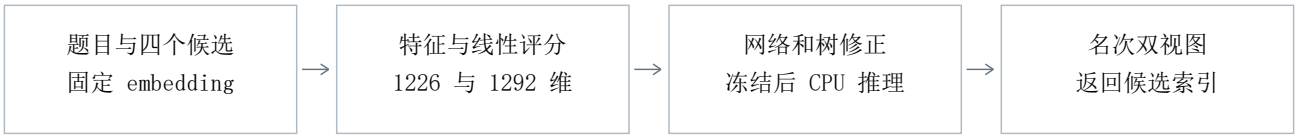


图 1 最终管线只读取传入的输入和冻结资产。

2 特征与线性评分

148 维文本特征覆盖长度、数字与等号数量、表达标记、算式成立比例、答案共识，以及部分特征的组内差值、标准化差值和名次。原始数值可描述一条解答，组内比较则帮助模型区分同题的四个候选。

特征块	维度	使用方式
文本与组内比较	148	进入两个线性模型，也用于网络和树。
官方 embedding	1024	使用原始表示，由所属训练部分计算标准化统计量。
数量来源	54	18 个原始量，加组内差值和标准化差值。
表达式可达性	66	22 个原始量及两类组内比较，加入第二个线性模型。
数量图	34	为网络和树提供路径、覆盖率与单位等软证据。
题目条件交互	132	12 类题目提示与 11 项候选证据相乘，供树使用。

2 1 算式来源与可达性

数量来源模块尝试把算式操作数连接到题目数值或较早的计算结果，再追踪最终答案的来源。数量图保留同值不同来源的备选路径，提取覆盖率、深度、未知操作数和单位匹配等特征。这些判断作为软特征参与学习，不直接否决候选。

表达式搜索最多处理 5 个题目数量，以互不重叠的数量子集组合加减乘除，每个数量出现位置在一个表达式中最多使用一次。每个子集至多保留 128 个状态；超限时，分别保留生成频次较高及接近候选最终数值的状态。这里使用的是候选给出的答案，不是参考答案。数量过多时返回零特征。

2 2 线性目标与概率融合

来源模型共 1226 维，表达式模型共 1292 维。均值与标准差只用所属训练部分计算。若一题有 m 个正确候选，每个正确候选的目标概率为 1/m，其余为 0。

```
s_ij = ((x_ij - mu) / sd) @ w + b
L = -mean_i sum_j t_ij log softmax(s_i)_j + lambda ||w||^2
p0 = 0.75 softmax(s_provenance) + 0.25 softmax(s_expression)
```

两个模型的 L2 系数分别为 0.006 和 0.012，权重从零初始化，L-BFGS-B 最多迭代 350 次。原始 embedding 只进入线性评分器；后续小网络和树通过基础分数利用它的信息。

3 小型修正模型

3 1 有界神经修正

网络输入为 148 维文本特征、54 维来源特征、34 维数量图和 66 维表达式特征，共 302 维，再加基础对数概率及其组内中心化值，得到 304 维。输入按训练统计量标准化，标准差至少取 0.01，并截到 [-8,8]。

共享候选网络为 304 维输入、32 维 ReLU 隐层和一个 tanh 输出，共 9793 个可训练参数。tanh 把修正限制在 [-1,1]。损失为均匀正确候选交叉熵，加 0.02 倍修正值平方均值；无法解析答案的候选被屏蔽。

设置	取值
随机种子	11、23、47，三个输出取均值
优化器	AdamW，学习率 0.001，weight decay 0.05
正则与批量	dropout 0.3，batch 128，梯度裁剪 5
导出轮数	搜索比较 10、30、60 轮，最终取第 30 轮快照

固定重训保留原有的 60 轮计算过程，再导出第 30 轮快照，训练计时包含这些计算。训练使用单张 RTX 5070；评测时用 NumPy 执行前向计算，不加载 PyTorch。

3 2 树修正

树使用上述 304 维和 132 维题目条件交互，共 436 维输入。它以训练折外基础对数概率作为初始分数，逐轮拟合四候选 softmax 交叉熵的梯度。相比单独线性项，树能表达多个证据同时成立时的变化。

模型	叶数	最小叶样本	L2 与种子
单个模型	7	60	L2=10，种子 73
三模型均值	15	100	L2=20，种子 73、101、137

每个模型均为 160 轮，学习率 0.03，feature_fraction=0.8，max_bin=63。训练用 LightGBM 4.6.0，随后导出节点数组。导出预测与原库逐份对照，允许误差 atol=rtol=1e-10，正式推理不导入 LightGBM。[6]

```
S = log(p0) + 0.046875 mean(R) + 0.140625 T7
    + 0.0625 mean(T15)
```

R 表示三个网络，T7 为 7 叶树模型，T15 表示三个 15 叶模型。修正权重较小，基础概率仍主导多数选择。完整评测包含所有成员与两次特征视图评分。

4 交叉验证与名次修正

4 1 避免教师分数的训练泄漏

修正器不能只看到教师对已拟合样本的分数。否则，它学到的分数分布可能过于乐观。实验按题目分组三折；评估外折 k 时，教师和修正器都不使用该外折的标签。其余题目再做两折教师拟合，为修正器的训练题生成自身折外的基础分数。

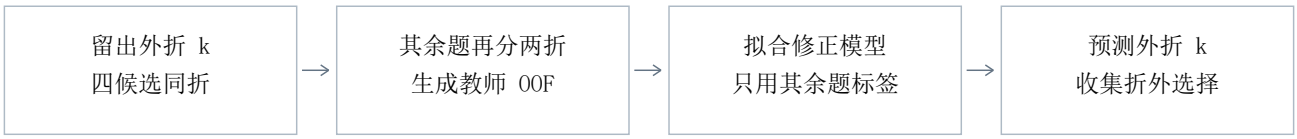


图 2 每个外折内的拟合顺序。OOF 指样本所属训练折之外的预测。

最终全量拟合时，两个线性模型使用全部相应训练题；修正器使用两套三折教师 OOF 概率的均值作为训练基础分数。折划分随包保存在 training_assets/folds.npz。固定网络种子为 11/23/47，树种子为 73/101/137；内层教师划分使用 930+k。

4 2 并列排序的顺序影响

原特征用两次 argsort 计算名次。数值并列时仍会分配不同名次，例如四项全相同可能得到 [0,1,2,3]，从而把候选位置带入评分。新视图只调整 16 个名次特征，其余值保持相同。

```
r_view = 0.75 r_original + 0.25 rank_average
S_final = 0.75 S(original_features) + 0.25 S(view_features)
```

四项相同的平均名次均为 1.5。平均名次函数在人工并列样例上，与全部 24 种排列所得名次的均值精确一致。模型本身仍保留原名次的一部分，并不保证对任意候选排列完全不变。两个视图使用相同权重，只提取一次文本、数量图与表达式特征。

4 3 选型结果

本轮在训练 OOF 上比较 4 个名次调整强度、4 个融合权重和 2 种分数融合方式，共 32 份配置。先筛选五份，再按 validation 正确数比较，并记录测试前源码与资产哈希。最终选用强度 0.25、融合权重 0.25、logit 融合。[4]

分歧训练题的 OOF 正确数从 1777 增到 1779/2114；validation 保持 755/798；test 从 392 增到 393/467。测试只改变了一个候选选择。这个单题增益说明该配置在当前题库有效，不能据此推断对任意新题均有相同收益。

5 实验对照与消融

5 1 开发阶段对照

完整 validation 的分母为 798，test 的分母为 467。多数投票统计有效解析答案的频次，平票时取输入顺序中的第一个候选。control 为旧项目三成员组内 MLP。各开发版本包含特征、正则和融合权重的联合变化。

方法	验证正确数	测试正确数	测试准确率
多数投票	688	323	69.16%
旧项目 control	747	378	80.94%
原线性方法	748	387	82.87%
增加数量来源	751	388	83.08%
表达式模型融合	753	389	83.30%
GPU 有界修正阶段	753	391	83.73%
单个树模型修正	754	392	83.94%
三种子树平均	755	392	83.94%
最终名次双视图	755	393	84.15%

5 2 固定权重的推理消融

固定权重消融只删除指定推理组件，不重新拟合。最终版本在分析前已固定。各变体共享特征，分别由官方独立评分器评分。[5]

固定权重变体	验证正确数	测试正确数	测试准确率
完整方法	755	393	84.15%
去掉神经修正	754	392	83.94%
去掉树修正	752	389	83.30%
去掉名次修正	755	392	83.94%
仅双线性与双视图	753	389	83.30%

去掉树修正下降 4 题；去掉网络或名次修正各下降 1 题。这些差值表示当前融合对组件的依赖，不是组件独立训练收益，不能相加。开发阶段的网络系数也与最终版不同，两个对照表不能混作同一种消融。

早期线性与 control 融合为 381/467，组内网络为 383/467；后续 GPU 损失融合与上下文网络均停在 391/467，这些配置没有进入最终管线。完整配置和搜索成本在 records/experiments/ 与 search_costs.csv。

6 资源与复现

项目	本次记录
推理资产	643,525 字节，约 0.614 MiB；上限 16 MiB
完整 test CPU	预测新进程 9.13 秒，独立评分 0.18 秒，合计 9.31 秒
本地硬件	Intel Core Ultra 5 250K Plus，评测四线程；训练单张 RTX 5070
独立重训	107.16 秒；PyTorch 峰值分配显存 88.07 MiB
依赖	Python 3.12.10；评测 NumPy 2.5.3；训练另需 SciPy 1.16.3、PyTorch 2.7.1+cu128、LightGBM 4.6.0

完整 CPU 时间包含进程启动、导入、数据和资产加载、全部特征及成员评分。校验与基线脚本不作为资源计时。参考机为 Xeon Platinum 8457C，最终 30 秒资格仍由参考机实测决定。显存记录是 PyTorch 分配量，不是整卡占用。

6 1 直接评测冻结模型

```
python -m venv .venv-eval
.\.venv-eval\Scripts\python.exe -m pip install -r code\requirements.txt
.\.venv-eval\Scripts\python.exe code\reproduce.py
```

在独立交付目录执行即可。评测环境只有 NumPy，推理不需要 GPU、PyTorch、LightGBM、SciPy 或网络。默认 checkpoint 是 code/runs/model_bundle，评分写入 code/runs/reproduction。

6 2 重新训练

```
python -m venv .venv-train
.\.venv-train\Scripts\python.exe -m pip install -r code\requirements-train.txt
.\.venv-train\Scripts\python.exe code\train_export.py
.\.venv-eval\Scripts\python.exe code\reproduce.py `
  --checkpoint runs/retrained_bundle `
  --output-dir runs/retrained-reproduction
```

固定训练只用 train 参考答案，不依赖旧项目或预测缓存。本次整理后重新训练，validation/test 与冻结版逐题一致。表达式线性模型、三个网络及四个树模型逐字节一致；来源线性模型有浮点差异。跨平台不保证权重逐字节一致，可用提供的冻结权重直接复现。

6 3 版本对应

```
method SHA-256
10aaffbf69af46348703c03a53e4211d3e2adcf12c4604b7e1a97ed6c3bc4706
```

官方代码基线提交为 bb801f4f2e7629d270df765ab12c333b2dc616bb。METHOD_MANIFEST.json 对应推理代码和 checkpoint，CHECKPOINT_MANIFEST.json 列出全部资产哈希；原测试前源码另存于 records/selection/source_snapshot。

7 讨论与复用说明

7 1 仍然存在的错误

算术成立并不能排除题意理解错误。例如训练题中，一次租金为 150 美元、每英里 0.50 美元，两天分别行驶 620 和 744 英里，费用应为 150+0.50×(620+744)=832。错误候选将固定租金分别计入两天，得到 982；局部加乘仍可成立。现有数量图与来源特征只能提供线索，不能完整判定费用、时间或指代关系。

表达式可达性也有边界。它限制数量数目、每个数量的使用次数和状态数，部分隐含常数、重复使用数量的正确解法或复杂单位转换可能被遗漏；百分比与单位别名只作近似处理。因此，系统使用这些值作软特征，而不把可达性当作答案证明。

后续曾尝试答案组聚合、并列名次重训和直接 top-one 目标，均未超过原验证成绩。保守题目关系校验把训练 OOF 分歧题提高到 1782/2114，但官方 test 仍为 393/467，且 467 个选择与原版相同。最终交付保持本报告的名次双视图版本。

7 2 对成绩的解释

训练 OOF 和 validation 都参与过方法选择，不能视作独立泛化评估。公开 test 分数在开发中被反复观察，也可能产生间接反馈。没有使用 test 参考答案拟合权重、生成规则或构造单题答案表；这里将公开分数用于描述已冻结配置的可复现表现，不宣称未受开发过程影响的盲测成绩。

7 3 AI 与代码复用

AI 助手参与特征、训练与推理代码、实验运行、目录整理及报告撰写。148 维特征和算术检查复用原项目；数量来源提取复用 quantity_features_v2.py；树节点导出结构参考原 tree_training.py。新增组内比较、数量图、表达式搜索、修正模型及名次双视图在开发过程中实现。报告文字编辑参考 Humanizer。[7]

问题与参考答案来自官方分发的 GSM8K 数据，候选及表示由 Qwen3-0.6B 生成，模型修订号见数据 manifest。没有额外数据或预训练权重；官方 LICENSE.txt 与 NOTICE.txt 随包保留。

参考资料

[1] DASE7506 MP2 GUIDE 与官方接口，固定提交 bb801f4f。

[2] code/data/manifest.json，数据规模、Qwen 修订号及原始文件哈希。

[3] code/runs/reproduction/summary.json 与 records/retraining/summary.json，官方分数和完整进程时间。

[4] records/selection/order-freeze-original.json，测试前配置、源码及权重哈希。

[5] records/ablations/summary.json 与 report/evidence.json，固定权重消融及报告数值。

[6] LightGBM 4.6.0 自定义目标与模型导出接口。

[7] blader Humanizer，文字编辑参考。