多证据融合的数学推理候选选择

DASE7506 MP2 实验报告　2026 年 10 月 31 日

摘要

针对同一道数学题的四条候选解答，本文融合文本表示、答案共识、数量来源与表达式证据，建立轻量候选选择器。两个线性模型给出基础概率，小型神经网络与树模型学习证据之间的组合关系，名次双视图进一步调整并列特征的评分。最终方法在官方测试集上选对 393/467 题，准确率为 84.1542%，较原 control 基线多选对 15 题，提高 3.2120 个百分点。全部推理资产未压缩为 643,525 字节，本地四线程完整 CPU 评测用时 9.31 秒。从头重训与冻结权重的逐题选择一致。

1 任务与方法概览

任务输入为题目、四条 Qwen3-0.6B 候选解答及每条解答固定的 1024 维表示，输出为一个候选索引。官方数值解析器比较候选最终答案与参考答案，并按完整题库的选择准确率评分。[1][2]

最终数值不同的候选可能都具有完整的文字和局部正确的算式。本文将解答本身的表征与数量关系结合：线性模型综合单项证据，修正模型学习多个证据同时出现时的评分变化，双视图缓和并列名次携带的顺序信息。整个管线使用冻结资产在 CPU 上执行。

数据集	题数	有效答案分歧题
train	4755	2114
validation	798	355
test	467	467

分歧题指候选中存在至少两个不同的有效解析答案。线性模型拟合 train 中含错误候选的 2513 题；网络与树拟合 2114 道分歧题。四个候选始终按题目归入同一训练折。验证集的 443 道非分歧题较易选择；分歧部分成绩为 312/355（87.8873%），完整验证集为 755/798（94.6115%）。

2 结合文本与数量关系的基础评分

文本与组内比较特征描述解答长度、数字与等号数量、表达标记、算式成立比例和答案共识，并对部分特征计算组内差值、标准化差值与名次。同题比较把一条解答的绝对属性转化为四个候选之间的区别。

特征块	维度	用途
文本与组内比较	148	线性模型、网络和树
官方 embedding	1024	两个线性模型
数量来源	54	18 项原始量及两类组内比较
表达式可达性	66	22 项原始量及两类组内比较
数量图	34	网络和树的路径及单位证据
题目条件交互	132	树模型的条件与证据组合

2 1 数量来源与表达式证据

数量来源模块把算式操作数连接到题目数值或较早的计算结果，并追踪最终答案的计算来源。数量图保留同值不同来源的备选路径，提取覆盖率、路径深度、未知操作数和单位匹配等特征。模型据此区分使用题目数量的计算与来源不明的局部运算。

表达式搜索最多处理 5 个题目数量，按互不重叠的数量子集组合加减乘除，每个数量出现位置至多使用一次。每个子集保留至多 128 个状态，优先保留生成频次较高及接近候选最终数值的状态。超过数量上限时返回零特征。可达性作为评分证据参与学习，状态裁剪与单位近似共同规定了其适用范围。

2 2 线性模型与概率融合

数量来源模型使用 1226 维输入，表达式模型再加入 66 维特征，合计 1292 维。所属训练部分提供标准化统计量。训练使用四候选 softmax 交叉熵；一题有 m 个正确候选时，分别赋予 1/m 的目标概率。两个模型的 L2 系数为 0.006 和 0.012，权重从零初始化，以 L-BFGS-B 最多迭代 350 次。

$$p_0 = 0.75\,softmax(s_{来源}) + 0.25\,softmax(s_{表达式})$$

原始 embedding 进入线性模型。基础概率将其信息传递给后续修正器，同时保留由数量关系构成的显式证据。

3 学习证据组合的修正模型

3 1 有界神经修正

网络输入由 148 维文本特征、54 维数量来源、34 维数量图和 66 维表达式证据组成，共 302 维；加入基础对数概率及其组内中心化值后为 304 维。输入按训练统计量标准化，标准差下限为 0.01，随后截到 [−8, 8]。

所有候选共享一个 304→32→1 网络，隐层使用 ReLU，输出使用 tanh，每个网络有 9793 个参数。输出范围 [−1, 1] 限制单个修正器对基础评分的影响。训练目标为正确候选均匀交叉熵，加 0.02 倍修正值平方均值，并屏蔽无法解析答案的候选。

设置	固定取值
网络种子	11、23、47，输出取均值
优化器	AdamW；学习率 0.001；weight decay 0.05
正则与批量	dropout 0.3；batch 128；梯度裁剪 5
导出快照	第 30 轮；固定计算过程共 60 轮

3 2 树修正与最终融合

树模型在 304 维输入上加入 132 维题目条件交互，共 436 维。交互特征将 12 类题目提示与 11 项候选证据相乘。树以教师折外基础对数概率为初始分数，拟合四候选交叉熵的梯度，补充线性模型难以表示的条件组合。

模型	叶数	最小叶样本	L2	种子
单模型	7	60	10	73
三模型均值	15	100	20	73、101、137

各树模型训练 160 轮，学习率 0.03，feature_fraction=0.8，max_bin=63。LightGBM 4.6.0 模型导出为节点数组，逐份核对原库与数组预测，误差容限 atol=rtol=10^{-10}。[6]

$$S = \ln(p_0) + 0.046875\,\overline{R} + 0.140625\,T_7 + 0.0625\,\overline{T}_{15}$$

$\overline{R}$ 为三个网络输出均值，T_7 为 7 叶树模型，$\overline{T}_{15}$ 为三个 15 叶模型的均值。正式推理以 NumPy 完成网络前向计算和树遍历，所有成员均计入完整评测用时。

4 折外训练与名次双视图

4 1 按题目生成教师折外分数

修正器以教师在线性模型训练集之外产生的分数为训练输入，使其看到的分数分布接近实际推理。实验采用按题目分组的外层三折。评估外折 k 时，其余题目再划为两折，生成用于修正器训练的教师折外分数；随后用其余题目拟合的教师和修正器预测外折 k。

最终全量拟合时，两个线性模型使用全部相应训练题；修正器的基础分数来自两套三折教师折外概率的均值。每题四个候选保持同折，内层教师划分种子为 930+k。固定折划分位于 code/training_assets/folds.npz，网络与树种子见第 3 节。

4 2 用平均名次处理并列特征

原特征通过两次 argsort 生成名次。数值相同的候选仍可能得到不同名次，例如四项全相同会得到 [0, 1, 2, 3]。第二个视图把 16 项名次特征与并列平均名次混合，其余特征保持一致。

$$r' = 0.75\, r + 0.25 r_{平均}$$

$$S_{final} = 0.75\, S(X) + 0.25\, S(X')$$

四项相同时，平均名次均为 1.5。该函数在人工并列样例上与全部 24 种排列所得名次的均值精确一致。两个视图共享权重，文本、数量图和表达式特征提取一次，再分别评分。混合保留原有名次信息，候选顺序仍可能影响部分选择。

4 3 固定配置的选择依据

训练折外评估比较 4 个名次调整强度、4 个视图融合权重和 2 种融合方式，共 32 份配置。筛选五份后，以 validation 正确数确定强度 0.25、融合权重 0.25 与 logit 融合，并在测试前保存源码和资产哈希。[4]

该配置在 2114 道分歧训练题上的折外正确数为 1779，比原视图多 2 题；validation 为 755/798。官方 test 为 393/467，比原视图多选对 1 题。双视图提供了当前固定配置的增量收益，其影响同时由第 5 节的推理消融检验。

5 准确率与关键组件的实验验证

5 1 在相同评测协议下比较选择器

表中各方法使用相同数据划分与官方评分器。多数投票统计有效解析答案的频次，平票时取输入顺序中的第一个候选。control 为原项目的三成员组内 MLP；原线性方法为增加数量关系和修正器之前的起点。

方法	validation 正确数	test 正确数	test 准确率
多数投票	688	323	69.1649%
原 control	747	378	80.9422%
原线性方法	748	387	82.8694%
本文完整方法	755	393	84.1542%

完整方法较多数投票多选对 70 题，较 control 多选对 15 题，较原线性方法多选对 6 题。结果支持将候选表示、数量证据与小型修正器结合的选择方案。该比较反映完整方法的综合效果；组件作用由固定权重消融进一步区分。

5 2 固定权重消融定位组件作用

保持训练权重与其余推理步骤固定，分别移除神经修正、树修正和名次修正，另保留一个双线性与双视图组合。各变体共享特征提取结果，单独交给官方评分器评分。[5]

推理配置	validation 正确数	test 正确数	test 准确率
完整方法	**755**	**393**	**84.1542%**
移除神经修正	754	392	83.9400%
移除树修正	752	389	83.2976%
移除名次修正	755	392	83.9400%
双线性与双视图	753	389	83.2976%

完整配置相对移除树修正的配置多选对 4 题，相对移除网络或名次修正的配置各多选对 1 题。树修正在当前融合中承担较大的增量作用，网络与双视图进一步调整少数边界选择。这些差值衡量冻结模型对组件的依赖，受组件间交互影响，不作可相加的独立训练收益解释。

完整开发配置及搜索成本保存在 records/experiments/ 和 records/search_costs.csv；正文以最终方法、基线和固定消融构成对照。

6 计算成本与独立复现

项目	实测或固定配置
推理资产	未压缩 643,525 字节，约 0.614 MiB；课程上限 16 MiB
完整 test CPU	预测 9.13 秒，独立评分 0.18 秒，合计 9.31 秒
本地硬件	Intel Core Ultra 5 250K Plus；评测四线程；训练 RTX 5070
从头重训	107.16 秒；PyTorch 峰值分配显存 88.07 MiB
软件环境	Python 3.12.10；NumPy 2.5.3；SciPy 1.16.3；PyTorch 2.7.1+cu128；LightGBM 4.6.0

完整 CPU 时间包含新进程启动、导入、数据和资产加载、全部特征及各成员评分。显存为 PyTorch 分配量。课程的 30 秒资格以四线程 Xeon Platinum 8457C 参考机实测为准。[1][3]

6 1 评测冻结权重

在独立项目目录的 PowerShell 中运行以下命令。评测仅需 NumPy，默认权重位于 code/runs/model_bundle，评分写入 code/runs/reproduction。

```
python -m venv .venv-eval
.\.venv-eval\Scripts\python.exe -m pip install -r code\requirements.txt
.\.venv-eval\Scripts\python.exe code\reproduce.py
```

6 2 从头训练与版本对应

```
python -m venv .venv-train
.\.venv-train\Scripts\python.exe -m pip install -r code\requirements-train.txt
.\.venv-train\Scripts\python.exe code\train_export.py
.\.venv-eval\Scripts\python.exe code\reproduce.py `
  --checkpoint runs/retrained_bundle `
  --output-dir runs/retrained-reproduction
```

固定训练使用 train 输入与参考答案，从头生成教师折外分数和修正模型。本次重训与冻结版在 validation/test 的逐题选择一致；表达式线性模型、三个网络及四个树模型逐字节一致，来源线性模型的浮点差异未改变选择。

官方基线提交为 bb801f4f2e7629d270df765ab12c333b2dc616bb。METHOD_MANIFEST.json 绑定推理代码与权重，CHECKPOINT_MANIFEST.json 记录资产哈希。本方法标识为：

```
10aaffbf69af46348703c03a53e4211d3e2adcf12c4604b7e1a97ed6c3bc4706
```

6 3 代码与检查点地址

代码仓库地址：https://github.com/qutcal-alt/DASE7506-MP2

检查点目录地址：https://github.com/qutcal-alt/DASE7506-MP2/tree/main/code/runs/model_bundle

目录含 9 份 NPZ 与 config.json，可从 Code 菜单下载 ZIP 后按第 6.1 节评测。文件哈希及版本对应关系分别见 CHECKPOINT_MANIFEST.json 与 METHOD_MANIFEST.json。

7 讨论与结论

7 1 数量证据的适用范围

数量来源和表达式搜索为候选评分提供计算结构。题意中的固定费用、时间范围与指代关系仍需语义判断。例如一次租金为 150 美元、每英里 0.50 美元，两天分别行驶 620 和 744 英里，费用为 832 美元；把固定租金按两天重复计入会得到 982 美元，相关局部加乘仍能成立。该例说明，局部算术成立与题意关系一致需要分别建模。

表达式搜索的数量上限、单次使用约束和状态裁剪决定其覆盖范围；隐含常数、重复使用同一数量及复杂单位转换可能需要额外表示。本文把这些证据交给模型综合评分。测试最终数值正确的候选，其每步推理也未必正确。

7 2 评测范围

训练折外结果与 validation 用于方法选择。开发期间曾多次查看公开 test 分数，因此 84.1542% 表示冻结配置在该公开题库上的可复现成绩，独立泛化能力仍需新的留出数据评估。参数拟合使用 train 参考答案；test 参考答案用于官方评分与复现。

7 3 AI 使用情况与代码复用

本项目使用 AI 助手 Codex 辅助撰写训练与推理代码，并协助整理目录、撰写与润色报告。组内比较、数量图、表达式搜索、修正模型和名次双视图在项目开发中实现。数据与候选表示使用官方分发版本，许可证和归属随包保留。

7 4 结论

本文以两个线性评分器连接固定表示与数量证据，用小型网络、树模型和名次双视图完成候选选择。官方测试成绩为 393/467（84.1542%），较原 control 多选对 15 题；固定消融支持各修正组件在当前融合中的增量作用。643,525 字节的冻结资产可直接进行离线 CPU 推理，从头重训也复现了相同的逐题选择。

参考资料

[1] DASE7506 MP2 GUIDE，官方提交 bb801f4f。https://github.com/xudongwu-0/DASE7506-MP2

[2] code/data/manifest.json，数据规模、表示模型修订号与原始文件哈希。

[3] code/runs/reproduction/summary.json；records/retraining/summary.json，完整评测与重训记录。

[4] records/selection/order-freeze-original.json，测试前配置、源码及权重哈希。

[5] records/ablations/summary.json；report/evidence.json，固定权重消融及报告数值。

[6] LightGBM 4.6.0 文档。https://lightgbm.readthedocs.io/en/v4.6.0/pythonapi/lightgbm.train.html